

A Three-Dimensional Analysis for LLM Deployment

A hospedagem de um modelo LLM requer a avaliação de diversos fatores, designadamente a capacidade do hardware para executar o modelo, os recursos de memória requeridos e o desempenho esperado em termos de velocidade e capacidade de resposta para o utilizador. Estes temas são fundamentais, tanto para utilizadores individuais como para organizações que pretendem implementar soluções de Inteligência Artificial de forma eficiente.

Para responder a estas questões, proponho uma abordagem baseada em três dimensões principais:


Hardware

A dimensão de **Hardware** visa determinar se os recursos computacionais disponíveis são suficientes para executar um modelo específico de forma eficiente e célere.


Para a presente análise, são consideradas duas métricas fundamentais do processo de inferência:

Prefill	Corresponde ao momento em que o modelo processa e interpreta o prompt fornecido pelo utilizador. Nesta fase, todos os tokens de entrada são submetidos a uma análise, de modo a construir o contexto necessário à geração da resposta. Durante o prefill, o modelo processa todo o prompt numa única forward pass. Cada token tem em conta a si próprio e todos os tokens que o precedem, construindo assim uma representação contextual.
Decode	Nesta fase, o modelo gera output tokens sequencialmente, com base em todos os tokens anteriores (incluindo o prompt e quaisquer output tokens previamente gerados). Para cada novo token, o modelo executa uma forward pass e utiliza mecanismos de Attention para considerar todo o contexto acumulado da conversa.

Hardware Analysis on Qwen3-4B-Base 2k Context



Hardware Analysis on Qwen3-4B-Base 4k Context




A dimensão **Tempo** visa avaliar a qualidade da experiência do utilizador, medindo a celeridade com que o sistema responde e gera um output.


São consideradas duas métricas fundamentais:

TTFT	<i>Time To First Token</i> (TTFT) corresponde à latência entre a receção do prompt e a geração do primeiro token de saída. Esta métrica abrange a fase de Prefill, na qual o modelo processa o contexto completo e gera o KV cache, bem como a primeira iteração da fase de Decode, responsável pela produção do primeiro token autoregressivo.
Latência	Latência é a métrica que avalia a experiência do utilizador. Mede o tempo decorrido entre o envio do prompt e a geração de uma resposta completa. Esta métrica abarca todas as fases do pipeline de inferência, incluindo a Tokenização, o Prefill, o Decode e a geração do output, refletindo, deste modo, o comportamento end-to-end do sistema.

Time Analysis on Qwen3-4B-Base 2k Context




Time Analysis on Qwen3-4B-Base 4k Context



Memória

A dimensão **Memória** visa avaliar a quantidade de memória requerida para executar um modelo de linguagem à medida que o tamanho do contexto aumenta. Esta métrica não se limita à consideração do tamanho dos parâmetros do modelo, mas também inclui o impacto dinâmico do KV Cache (Key-Value Cache).


Memory Analysis on Qwen3-4B-Base



O KV Cache cresce linearmente com o número de tokens no contexto, sendo reutilizado durante a fase de decode para evitar o recálculo da Attention sobre tokens anteriores. Assim sendo, embora reduza significativamente o custo computacional da geração, introduz um custo adicional em memória que pode tornar-se o principal fator limitante em contextos longos.

Model Scorecard Qwen3-4B-Base

GPU BF16 GPU Q4 CPU llama.cpp BF16 CPU llama.cpp Q4 CPU BF16



Foram consideradas as seguintes métricas como ideais: Prefill: > 3k tok/s. Decode: > 30 tok/s. TTFT: < 500 ms. Latência total: < 2 s (para respostas curtas 150 TOKENS)

Tamanho Modelos	Hardware	Recomendações	Tarefas
0.5B - 1.5B	CPU / GPU	Qwen Family	Hospedagem em telemóveis Extração estruturada Autocomplete Agentes ultra especializados
2B - 4B	CPU / GPU	Qwen Family e Meta	RAG simples Coding leve Automação Empresarial Assistentes corporativos baratos Automação de documentação
5B - 9B	CPU / GPU	Qwen Family, Meta e Mistral	Coding sério RAG avançado Agentes e automação ChatBot
12B +	GPU	OpenAI, Nvidia, Deepseek	Agentes mais viáveis Escrita e síntese