



Automatic Speech Recognition



Abstrato

Automatic Speech Recognition é a área de Inteligência Artificial responsável por converter áudio em texto automaticamente. O objetivo de um sistema ASR é receber um sinal de áudio e produzir a transcrição correspondente, da forma mais precisa possível.

Capacidades	Limitações	Utilidade
Transcrição	Ruído Overlapping Speech Áudio com baixa qualidade Palavras técnicas	Call Centers
Deteção de Linguagem		Podcasts
Speaker Diarization		Media
Sentence Timestamps		Voice Assistants
Emotion Recognition		Robotics
		Automotiva



Evolução

Atualmente a arquitetura Transformer domina esta área, mas não foi sempre assim:

1980 - 2010

Sistemas tradicionais fundamentados por Hidden Markov Models (HMM).

Exemplos: Kaldi

2010 - 2017

Deep Learning domina a área. Convolutional Neural Networks (CNN) e Recurrent Neural Networks (RNN) impulsionam o ASR para outro nível.

Exemplos: DeepSpeech


2017 - Presente

Arquitetura Transformer revoluciona toda a área da Inteligência Artificial.

Exemplos: Whisper e Canary




Funcionamento e Componentes



Pré Processamento	Representação Acústica	Encoder	Embeddings
Normalização do Volume	Log-Mel Spectrogram	Accoustic Encoders	Output
Remoção do Silêncio	MFCC (Mel Frequency Cepstral Coefficients)	Self - Supervised Encoders	
Redução de Ruído	Raw Waveform		

Exemplos de Accoustic Encoders: CNN Encoders, RNN Encoders, **Conformer Encoders**

Exemplos de Self - Supervised Encoders: **wav2sec**, HuBERT



Embeddings	Geração Auto Regressiva
O output do Encoder, é o input do Decoder	Converte os embeddings para tokens e gera texto

Tipos de Decoder's	Vantagens	Limitações
CTC Decoder (Connectionist Temporal Classification)	Muito rápido, simples, excelente para streaming	Pouco contexto linguístico e mais erros em frases ambíguas
Attention Decoder	Elevada precisão, melhor contexto	Mais caro e lento, menos adequado para streaming
Transformer Decoder	Excelente precisão, boa performance	Mais caro e lento
RNN-T Decoder	Streaming em tempo real, baixa latência	Específico para sistemas de baixa latência

Nem todos os modelos utilizam explicitamente todas estas etapas. Modelos recentes podem receber o Waveform diretamente ou aprender representações acústicas sem MFCC ou Log-Mel explícitos. Também nem todos os Decoders geram texto token a token.

É importante referir que o output de um Decoder não tem de obrigatoriamente ser texto.

Há várias finalidades, tais como, pontuação automática, timestamps por frases, diarização de oradores, classificação etc..



Métricas de Avaliação

Word Error Rate (WER)	Character Error Rate (CER)	Latência	Real Time Factor
Mede a percentagem de palavras reconhecidas incorretamente.	Semelhante ao WER mas mede o erro ao nível de caracteres.	Tempo que demora a realizar uma Transcrição.	Mede a velocidade de processamento relativamente à duração do áudio.



Modelos ASR em Português

Em 2025 a INESC-ID, tornou público primeiro [benchmark](#) que avalia a capacidade de modelos ASR na transcrição de áudio em Português Europeu.

Foram também disponibilizados [modelos](#) treinados com dados em Português Europeu.

Ainda neste ano, foi lançado um modelo dentro da família Amália baseado na arquitetura [SLAM-ASR](#), também orientado para ASR em Português Europeu.