



Automatic Speech Recognition



Abstrato

Automatic Speech Recognition é a área de Inteligência Artificial responsável por converter áudio em texto automaticamente.

A tarefa de converter linguagem falada em texto, é um pilar da moderna interação humano-computador, impulsionando aplicações que vão desde assistentes de voz a sistemas de controlo de veículos e serviços de transcrição automáticos.

Capacidades	Limitações	Utilidade
Transcrição	Ruído	Call Centers
Deteção de Linguagem	Overlapping Speech	Podcasts
Speaker Diarization	Áudio com baixa qualidade	Media
Sentence Timestamps	Palavras técnicas	Voice Assistants
Emotion Recognition		Robotics
		Automotiva



Evolução

Atualmente a arquitetura Transformer domina esta área, mas não foi sempre assim:

1980 - 2010

Sistemas tradicionais fundamentados pela arquitetura Gaussian Mixture Model - Hidden Markov Model (GMM-HMM).

Exemplos: Kaldi

2010 - 2017

O advento das Deep Neural Network (DNN) substituiu os GMMs nos sistemas híbridos DNN-HMM, resultando em melhorias significativas.

Exemplos: DeepSpeech

2017 - Presente

Arquitetura Transformer revoluciona toda a área da Inteligência Artificial. A era moderna do ASR é definida por uma mudança de paradigma para End-2-End. (E2E)

Exemplos: Whisper e Canary



Áudio Digital

Representação Digital de um Áudio

Antes de passarmos aos modelos propriamente ditos é importante percebermos como o áudio é representado digitalmente.


[0.2, 0.7, -0.2, 0.5, 0.4, -0.7, -0.1, -0.6, 0.9]

Um áudio não é nada mais nada menos do que um *array de valores* onde cada valor representa a **amplitude** do sinal num determinado segundo.

Um dos fatores mais importantes num áudio digital, é o **Sampling Rate**. Quando ocorre a gravação de um áudio digitalmente, o conversor analógico - digital trabalha com um determinado número de amostras a cada segundo. **Sample Rate** é o número dessas amostras num segundo. Mais amostras podem ou não significar um áudio com melhor qualidade. É muito análogo aos FPS nos vídeos.

Time Domain Signal

Um áudio convertido para digital é chamado de **Time Domain Signal** porque o array representativo do áudio é baseado ao longo do tempo de duração do áudio.




Frequency Domain Signal


A frequência determina o número de ciclos que o sinal realizou naquele segundo. A frequência é calculada usando a Transformação Fourier.

A partir das frequências e das suas intensidades nasce o **Espectrograma**. Representação gráfica das frequências presentes num sinal de áudio digital ao longo do tempo, mostrando também a intensidade. Ou seja, é um gráfico 2D com 3 informações sucintas.

As frequências para os seres humanos não são perçetíveis de maneira linear. A diferença entre 500Hz e 1000Hz pode ser muito mais explícita do que a diferença entre 5000Hz e 5500Hz. Desta ideia surge o **Mel Espectrograma** baseado na Escala Mel que tem como objetivo representar de maneira mais humana possível, a frequência em todas as regiões do espectro, aumentando assim a resolução onde a nossa audição é mais sensível.




Funcionamento e Componentes



Pré Processamento	Representação Acústica	Encoder	Embeddings
Normalização do Volume	<i>Log-Mel Spectrogram</i>	Accoustic Encoders	Output
Remoção do Silêncio	MFCC (Mel Frequency Cepstral Coefficients)	Self - Supervised Encoders	
Redução de Ruído	Raw Waveform		

Exemplos de Accoustic Encoders: CNN Encoders, RNN Encoders, **Conformer Encoders**

Exemplos de Self - Supervised Encoders: **wav2sec**, HuBERT



Tipos de Decoder's	Vantagens	Limitações
CTC Decoder (Connectionist Temporal Classification)	Muito rápido, simples, excelente para streaming	Pouco contexto linguístico e mais erros em frases ambíguas
Attention Decoder	Elevada precisão, melhor contexto	Mais caro e lento, menos adequado para streaming
Transformer Decoder	Excelente precisão, boa performance	Mais caro e lento
RNN-T Decoder	Streaming em tempo real, baixa latência	Específico para sistemas de baixa latência

Nem todos os modelos utilizam explicitamente todas estas etapas. Modelos recentes podem receber o Waveform diretamente ou aprender representações acústicas sem MFCC ou Log-Mel explícitos. Também nem todos os Decoders geram texto token a token.

É importante referir que o output de um Decoder não tem de obrigatoriamente ser texto.

Há várias finalidades, tais como, pontuação automática, timestamps por frases, diarização de oradores, classificação etc..



Métricas de Avaliação

Word Error Rate (WER)	Character Error Rate (CER)	Latência	Real Time Factor
Mede a percentagem de palavras reconhecidas incorretamente.	Semelhante ao WER mas mede o erro ao nível de caracteres.	Tempo que demora a realizar uma Transcrição.	Mede a velocidade de processamento relativamente à duração do áudio.



Modelos ASR em Português

Em 2025 a INESC-ID, tornou público primeiro [benchmark](#) que avalia a capacidade de modelos ASR na transcrição de áudio em Português Europeu.

Foram também disponibilizados [modelos](#) treinados com dados em Português Europeu.


Ainda neste ano, foi lançado um modelo dentro da família Amália baseado na arquitetura [SLAM-ASR](#), também orientado para ASR em Português Europeu.



Caso Prático - Sistema Assobio

No levantar da cortina, foi construído o sistema **Assobio** que na versão original tem como objetivo, receber um áudio, realizar a transcrição desse mesmo áudio, passar a transcrição para um Small Language Model e o mesmo realizar uma auditoria suscentada pelo prompt do utilizador. No fim guarda tudo numa base de dados SQL.

Tem como feature especial, **Model Routing**, onde após a transcrição de cada áudio há uma condição (nesta versão é o número de letras) que aciona um modelo mais potente ou menos potente. O Routing também funciona em termos de Hardware, os modelos mais pequenos correm a Inferência na CPU usando o motor llama.cpp e os modelos mais potentes correm em raw GPU.





Caso Prático - Sistema Assobio - Benchmarks

	Modelo Whisper Large	Modelo Whisper PT
Greedy Decoding	● WER - 0.39 ● CER - 0.19 ● RTF - 0.34 ● Latência - 14.71	● WER - 0.54 ● CER - 0.44 ● RTF - 0.18 ● Latência - 7.76
Beam Search Decoding = 5	● WER - 0.36 ● CER - 0.18 ● RTF - 0.38 ● Latência - 16.33	● WER - 0.49 ● CER - 0.38 ● RTF - 0.31 ● Latência - 12.72
Beam Search Decoding = 10	● WER - 0.35 ● CER - 0.18 ● RTF - 0.49 ● Latência - 21.23	● WER - 0.48 ● CER - 0.36 ● RTF - 0.40 ● Latência - 16.48
VAD + ASR	● WER - 0.44 ● CER - 0.23 ● RTF - 0.57 ● Latência - 24.85	● WER - 0.44 ● CER - 0.36 ● RTF - 0.22 ● Latência - 9.84
Demucs + ASR	● WER - 0.41 ● CER - 0.22 ● RTF - 0.44 ● Latência - 19.19	● WER - 0.59 ● CER - 0.45 ● RTF - 0.33 ● Latência - 13.87
Noise Reducer + ASR	● WER - 0.52 ● CER - 0.30 ● RTF - 0.48 ● Latência - 21.49	● WER - 0.49 ● CER - 0.38 ● RTF - 0.25 ● Latência - 10.92
Peak Normalization + ASR	● WER - 0.37 ● CER - 0.18 ● RTF - 0.46 ● Latência - 19.26	● WER - 0.51 ● CER - 0.40 ● RTF - 0.30 ● Latência - 12.49
Demucs + Peak Normalization + Aumento Controlado do Volume + ASR	● WER - 0.38 ● CER - 0.21 ● RTF - 0.38 ● Latência - 16.42	● WER - 0.51 ● CER - 0.39 ● RTF - 0.28 ● Latência - 12.20
VAD + Demucs + Peak Normalization + Aumento Controlado do Volume + ASR	● WER - 0.46 ● CER - 0.24 ● RTF - 0.35 ● Latência - 15.39	● WER - 0.43 ● CER - 0.35 ● RTF - 0.24 ● Latência - 10.43

NOTAS:

- Real Time Factor e Latência foram apresentadas as médias.
- O Benchmark consiste num dataset modesto com áudios em Português Europeu e as respetivas transcrições.
- [IP/Automatic Speech Recognition/v2/Eval at master · Eliezer-Carvalho/IP](#)