

Context Engineering

Definição

O prompt é apenas uma peça da arquitetura. O verdadeiro desafio está em desenhar instruções que forneçam o contexto certo, escolham as ferramentas adequadas, validem as respostas e permitam ao sistema aprender com as interações.

Nesse sentido, é importante saber definir o contexto que vai ser entregue a um modelo dentro de um sistema e desta maneira aumentar a eficácia do mesmo.

Como um LLM funciona ?

Context Window

System Prompt

+

User Prompt

+

Histórico de Conversa

+


Tools

Um modelo não tem a capacidade de perceber o que é importante e o que não é. A única maneira do mesmo conseguir perceber é fornecendo um bom e organizado contexto.

Tokens e Context Window

Um prompt maior não é obrigatoriamente um prompt melhor. O objetivo do Context Engineering é maximizar a **qualidade** da informação fornecida e não a sua **quantidade**. Um contexto curto, relevante e bem organizado reduz custos, melhora a precisão e aproveita melhor a Context Window do modelo.

Número de Tokens de vários Prompts



Os Pilares de um bom Contexto

1. Definir o papel (*Role Prompting*)

Explica-me Machine Learning.

Explica-me Machine Learning como se fosses um Senior ML Engineer, aprofunda na linguagem técnica e mostra código Python como exemplos.

O papel ajuda a definir vocabulário, profundidade, estilo e exemplos. Orienta o comportamento para aquilo que definimos.

2. Definir a especificidade

Escreve um artigo.

Escreve um artigo de 1000 palavras. Inclui Introdução, Problema, Solução, Exemplos e Conclusão. Tom técnico.

Quanto menos espaço se deixar para ambiguidade, melhor.

3. Delimitadores

Resume isto: {texto enorme}

Resume apenas o conteúdo entre << e >>.

<< {texto enorme} >>

Os LLMs gostam de contexto organizado e são treinados com delimitadores, por isso é juntar o útil ao agradável.

4. Few-Shot Prompting

Traduz isto em formato JSON

Traduz isto em formato JSON.

Exemplos:

The kid went to the beach.

[{ "pt": "A criança foi à praia" }]

Tal como os humanos percebem melhor as coisas com exemplos, os LLM's seguem a mesma ideia.

5. Regras e Limitações

És um especialista em tradução.

Regras:

1. Não deves traduzir para nenhuma outra linguagem sem ser Português.

2. Deves ser direto e conciso.

És um especialista em tradução.

É importante o modelo saber o que fazer mas também o que não fazer.

6. Task Decomposition

Encontra uma relação entre estas tabelas.

1. Encontra primeiro a coluna que dá a informação dos clientes.

2. Depois seleciona apenas os clientes mais antigos.

3. Por fim cruza essa tabela com a coluna compras.

Encontra uma relação entre estas tabelas.

Dividir uma tarefa complexa em subtarefas melhora frequentemente a qualidade da resposta.

7. Self Consistency

Propõe abordagem diferentes.

Propões 3 abordagens diferentes, no fim compara-as e escolhe a mais robusta.

Em vez de aceitar a primeira resposta, pede-se várias e depois compara-se. A comparação pode ser feita pelo modelo ou por um humano.

8. Ordem da Informação

1. 1-2 frases para estabelecer o papel do modelo e a descrição da tarefa.

2. Estabelecer um tom.


3. Contexto como documentação, imagens ou dados.

4. Detalhar ainda mais a tarefa e definir Regras.

5. Mostrar exemplos. (Opcional mas recomendado)

6. Conclusão com foco na repetição das tarefas fulcrais.
-

Guardrails e Avaliação



Não existe Engenharia sem validação e avaliação!

Guardrails verificam se a resposta cumpre determinadas regras, como formato, estrutura ou políticas definidas. A **Avaliação** mede a qualidade do conteúdo produzido.

Ambas as fases podem ser realizadas por um humano ou através de métricas.



Técnicas Importantes

Este tópico é dedicado aos desenvolvedores.

Constraint Decoding	Em vez de pedir ao modelo para gerar num determinado formato, é possível restringir o espaço de geração.
Context Retrieval (RAG)	RAG permite alimentar um modelo apenas com o contexto realmente relevante.
Tool Calling	Com tools os modelos podem decidir quando receber contexto e de onde.
Context Compression	Muitas das vezes nem todo o contexto é relevante, é necessário remover lixo.

Exemplo

Tarefa e Objetivos

Tom

Regras

Conclusão

Contexto

<|im_start|>system

És um assistente de IA alimentado por um sistema RAG, que tem como único e principal objetivo responder a perguntas realizadas pelos utilizadores de acordo com o contexto fornecido.

Deves responder de maneira curta e direta, num tom amigável.

- Regras:
1. É fulcral e obrigatório que respondas apenas consoante o contexto fornecido.
 2. Não uses conhecimento externo.
 3. Se a resposta não existir no contexto, responde exatamente: "Informação não presente no contexto fornecido"
 4. Responde de forma breve e direta.
 5. Formata a resposta de forma clara.

Tens como principal e única função responder a perguntas de acordo com o Contexto fornecido. Não deves inventar nem aceder a informação externa. Fazes parte de um sistemas RAG e deves apenas responder de acordo com o Contexto fornecido.

<|im_end|>

<|im_start|>user

<Contexto>

{feed_llm}

</Contexto>

Pergunta:
{prompt}

<|im_end|>

<|im_start|>assistant

