


How To RAG



Fundamento e Definição

Fundamento	Os modelos trabalham com contexto limitado e o seu conhecimento está restrito aos dados utilizados durante o treino. RAG surge para combater estas limitações, recuperando informação relevante de uma base de conhecimento externa antes da geração da resposta.
Definição	Arquitetura que combina a recuperação de informação (<i>retrieval</i>) com a geração de texto (<i>generation</i>), permitindo que o modelo consulte uma base de conhecimento confiável e utilize essa informação para produzir respostas mais precisas, atualizadas e fundamentadas.

Problemas abordados pelo RAG

- Alucinações

Os modelos de linguagem apresentam algumas desvantagens, entre elas as Alucinações. Os modelos podem gerar respostas incorretas ou inventar informação quando não possuem conhecimento suficiente em relação a um tópico.


- Conhecimento Desatualizado

Os modelos são treinados com dados disponíveis até uma determinada data. Desse modo, informação ou conhecimento recente, não prevalece na resposta de um modelo.

- Acesso a conhecimento específico

Empresas e organizações possuem documentação interna, como manuais, procedimentos ou regulamentos que não estão presentes na fase de treino de um modelo.


How To RAG




Parsing	Converte os documentos em estruturas de texto tentando preservar ao máximo estrutura lexical e semântica.
Chunking	Converte texto corrido em pequenos excertos. É preciso ter em conta que chunks mal construídos podem cortar contexto a meio.
Retrieval	Coração de um sistema RAG. Etapa responsável por identificar e recuperar os chunks da base de conhecimento mais relevantes para a pergunta do utilizador.

How To RAG - Avançado

1. Parsing




2. Chunking



3. Embeddings

Afinal de contas o que são embeddings?

Os embeddings têm a capacidade de converter texto em vetores numéricos que representam significado semântico. A partir destes vetores podemos fazer comparações entre palavras e frases e perceber se os seus significados ou sentidos são parecidos. [1301.3781](#)



4. Vector Database

Em produção é completamente obrigatório! O utilizador insere os documentos e o processo até aqui pode ser guardado numa base de dados vetorial para evitar estar sempre a recomputar e a desperdiçar recursos.

5. Retrieval

Sparse Retrieval

– O mais antigo. Baseia-se na procura por similaridade lexical.

Dense Retrieval

– Tem como base embeddings. Baseia-se na procura por similaridade semântica. O mais famoso e obrigatório em qualquer sistema RAG.

Hybrid Retrieval

– Combina o melhor dos dois mundos. À boleia do algoritmo RRF (*Reciprocal Rank Fusion*) permite combinar tanto Sparse Retrieval como Dense Retrieval.

How To RAG - Técnicas Emergentes

Query Transformation	A query passa por uma transformação antes de entrar no sistema RAG. Query Rewriting, Query Expansion, HyDE, Multi Query Retrieval etc..
Context Expansion	Atinge o módulo de Retrieval. Usa Parent-Child Retrieval. Recupera um chunk pequeno e depois recupera os anteriores ao mesmo.
Reranking Forte	Logo após o Retrieval é possível adicionar um Reranker para ordenar os chunks de acordo com a pergunta recebida.

Avaliação de Sistemas RAG

- Avaliação do Retrieval

Sendo o Retrieval uma parte fulcral de um sistema RAG, o primeiro foco de avaliação é o mesmo.

<i>Recall@K</i>	Número de Chunks Relevantes / Número Total de Chunks Relevantes
<i>Precision@K</i>	Número de Chunks Relevantes / Número Total de Chunks Recuperados
<i>Mean Reciprocal Rank@K</i>	1 / Posição em que o primeiro chunk relevante apareceu
<i>HitRate@K</i>	Retorna 1 caso seja encontrado pelo menos um chunk relevante. Retorna 0 se não for encontrado nenhum chunk relevante


- Avaliação da Resposta

Segunda parte da avaliação. Não adianta ter um bom sistema RAG se o modelo não tem a capacidade de seguir o contexto.

<i>Answer Relevance</i>	A resposta dada pelo modelo responde à pergunta do utilizador ?
<i>Faithfulness</i>	A resposta está fundamentada pelo contexto fornecido ?

Caso Prático

Foi construído um mini sistema RAG para meter em prática todos estes conceitos abordados. A arquitetura de um sistema é a seguinte:




Caso Prático - Avaliação Retrieval

Métricas	Sparse Retrieval	Dense Retrieval	Hybrid Retrieval	
Recall@5	0,48	0,55	0,56	+ 0,08
Precision@5	0,15	0,18	0,19	+ 0,04
HitRate@5	0,63	0,70	0,70	+ 0,07
MRR@5	0,51	0,54	0,58	+ 0,07

Métricas	Sparse Retrieval	Dense Retrieval	Hybrid Retrieval	
Recall@10	0,55	0,66	0,66	+ 0,11
Precision@10	0,09	0,11	0,11	+ 0,02
HitRate@10	0,70	0,80	0,77	+ 0,10
MRR@10	0,52	0,56	0,59	+ 0,07


Métricas	Sparse Retrieval	Dense Retrieval	Hybrid Retrieval	
Recall@15	0,61	0,74	0,70	+ 0,13
Precision@15	0,07	0,08	0,08	+ 0,01
HitRate@15	0,74	0,85	0,81	+ 0,11
MRR@15	0,52	0,56	0,60	+ 0,08



Modelo Bi Encoder (jina-embeddings-v5-text-small-retrieval)

Caso Prático - Avaliação Retrieval + Reranker


Métricas	Sparse Retrieval + Reranker	Dense Retrieval + Reranker	Hybrid Retrieval + Reranker	
Recall@5	0,48	0,55	0,68	+ 0,20
Precision@5	0,16	0,18	0,20	+ 0,04
HitRate@5	0,63	0,70	0,82	+ 0,19
MRR@5	0,58	0,62	0,67	+ 0,09
Métricas	Sparse Retrieval + Reranker	Dense Retrieval + Reranker	Hybrid Retrieval + Reranker	
Recall@10	0,53	0,59	0,74	+ 0,21
Precision@10	0,16	0,18	0,20	+ 0,04
HitRate@10	0,71	0,74	0,85	+ 0,14
MRR@10	0,62	0,67	0,74	+ 0,12
Métricas	Sparse Retrieval + Reranker	Dense Retrieval + Reranker	Hybrid Retrieval + Reranker	
Recall@15	0,57	0,63	0,79	+ 0,22
Precision@15	0,17	0,19	0,21	+ 0,04
HitRate@15	0,74	0,79	0,89	+ 0,15
MRR@15	0,67	0,71	0,78	+ 0,11



Modelo Bi Encoder (jina-embeddings-v5-text-small-retrieval)

Modelo Cross Encoder (BAAI/bge-reranker-v2-m3)

Caso Prático - Avaliação Resposta



Caso Prático - RAG System Score

Qwen 2.5 - 0.5B - Instruct



Phi 3.5 Q4 - 4B - Mini Instruct



Na parte final, foi criada uma métrica que define o Score Final do Sistema RAG.

Foi usada a arquitetura Hybrid RAG + Reranker e foram comparados dois modelos.