





Synthetic Data

Fundamentos

Definição	Informação artificialmente criada por algoritmos ou simulações que mantém propriedades relevantes dos dados reais.
Importância	Data Scarsity Data Annotation Cost Privacidade
Limitações	Garbage In Garbage Out Fidelidade Bias

Tipos de Synthetic Data



Full Synthetic → Todo o dataset consiste em dados artificiais.

Hybrid Synthetic → O dataset é distribuído por dados artificias e dados reais.

Designing Synthetic Datasets

1. Definir Objetivos

“O que quero avaliar ?” | “Que tipo de modelo quero treinar ?” | “Que simulação quero realizar?”

Esta fase inicial serve para responder a estas perguntas. É fulcral ter um objetivo sólido e bem delineado.

Propósitos Synthetic Data

- Training Data Generation
- Evaluation Data Generation
- Simulação de um Ambiente



2. Contexto e Seed


Nenhuns dados são gerados do nada. Existe sempre uma base, um dataset já existente com alguns dados ou um contexto específico onde se quer realizar uma avaliação.

Situação	Solução
Escassez de dados na área da saúde	Usar dados já existentes como base para a geração de novos dados (<i>Seed</i>)
Avaliar o Retrieval de um sistema RAG	Usar o contexto que o sistema recupera para construir o dataset de avaliação (<i>Contexto</i>)
Realizar Fine Tuning de um LLM para um domínio específico	Usar dados já existentes do domínio para criar novos dados (<i>Seed</i>)

3. Taxonomia

A Taxonomia é uma forma estruturada de decompor aquilo que se quer avaliar/treinar em dimensões, capacidades e cenários. É uma fase que não pode ser saltada na construção de datasets tanto para avaliar como para treinar modelos.

Eval Taxonomy vs Training Taxonomy



Training Taxonomy → Cobrir sub temas de um tema genérico.

Eval Taxonomy → Testar todos os cenários para descobrir onde falha.

4. Dataset Design e Schema

Em que formato queremos o output ? Nesta fase é importante ter em conta os metadados, que são bastante importantes na criação de datasets. JSON é de longe o formato de eleição.

Técnicas Importantes	Definição
Prompt Constraint	A mais simples. Pedir ao modelo para obedecer a um formato.
Structured Output	O modelo recebe um schema e responde no formato daquele schema.
Constrained Decoding	Elimina tokens que não são necessários para a geração de acordo com o formato pretendido.
Grammar Based Decoding	Aqui limitamos a gramática do modelo.

5. Synthetic Data Generation

Single Model vs Multi Model

Single Model Generation	Multi Model Generation
Um modelo vai gerando os dados.	Vários modelos geram dados.
Menos complexo mas com pior performance.	Sistemas com vários modelos com papeis diferentes - Gerador, Critico e Improver.

Técnicas de Geração

Self Instruct	O modelo cria os seus próprios exemplos de instruções.
Evol Instruct	O modelo cria os seus próprios exemplos de instruções mas cada vez mais difíceis.
Self Consistency Sampling	Em vez de gerar uma resposta, o modelo gera várias e depois é selecionada a melhor.

Estas técnicas são mais importantes na criação de datasets para treinar LLM's.

6. Verificação e Data Science

A geração de dados sintéticos traz problemas comuns aos LLM's tais como, Hallucination, Duplicados ou Distribution Collapse (todos os exemplos parecem iguais).

É obrigatório que exista uma fase de verificação rápida humana e aplicação de Data Science para analisar os dados criados.

Técnicas Importante	Técnicas
Eliminar duplicados	Usar Hashes para remover duplicados. SHA-256.
Eliminar duplicados por similaridade lexical	Calcular similaridade de Jaccard entre exemplos e perceber quais são os mais parecidos.
Avaliação de cada exemplo usando heurísticas simples	Comprimento de cada exemplo, rácio de caracteres únicos, repetição, linguagem
Eliminar duplicados por similaridade semântica	Usamos modelos Encoder para calcular a similaridade do Cosseno entre embeddings

7. Evaluation

A fase de avaliação serve para perceber se o dataset tem valor. Não existem métricas universais, mas consoante o tipo de objetivo podem-se definir algumas métricas.

Objetivo	Avaliação Proposta
Testar o Retrieval de um sistema RAG	Perguntas são fieis ao contexto ?
	Os chunks recuperados existem mesmo no sistema ?
Construir um dataset para realizar Fine Tuning	Diversidade das perguntas usando Embeddings
	Haverá muitas repetições nas perguntas ?
	Qualidade linguística
	Cobertura de temas segundo a Taxonomia adotada
Aumentar o número de dados de um sensor para treinar um modelo de ML	Nível de dificuldade das perguntas
	Os dados são fieis aos originais ?
	Cobre todos os cenários possíveis ?

Uma maneira cada vez mais comum de calcular métricas é usando a técnica LLM-as-a-Judge. Na ausência de métricas diretas, pode-se recorrer a esta técnica mas com profissionalismo.

LLM-as-a-Judge	
Critérios de Avaliação	Ser conciso e minucioso nos critérios de avaliação. Pedir ao modelo “Avalia isto” não é solução.
Tipos de LLM-as-a-Judge	● Pointwise Evaluation → Avalia uma resposta isoladamente. ● Pairwise Evaluation → Compara duas respostas. ● Ranking Evaluation → Cria um rank das respostas.
Self-enhancement Bias	Problema que pode surgir caso o Judge seja da mesma família de modelos que o Gerador.
Structured Output	Pode ser importante para desconstruir uma avaliação em vários scores.
Judge Prompt Engineering	Já abordado no primeiro ponto mas bastante importante.
Multi Judges	Mais quem um Judge.

8. Synthetic Data Refinement

Consoante resultados obtidos, é um excelente hábito pedir a um modelo para melhorar e dificultar os dados já criados. Desta maneira podemos tornar os dados mais desafiantes e melhor estruturados. Não é uma etapa obrigatória.

9. Dataset Curation

Tendo vários modelos a gerar dados sintéticos, no fim faz sentido juntar as melhores questões num dataset singular e assim atingindo o Golden Dataset.